

# Úvod do umělých neuronových sítí

**Závěrečná maturitní práce**

Vedoucí práce:  
Mgr. Blaha Marek

Andrea Hauptová

Brno 2018



Na tomto místě bych ráda poděkovala svému vedoucímu práce Mgr. Marku Blahovi za pomoc se stylistickou úpravou textu a za rady, které mi poskytl. Dále děkuji všem, kteří obětovali svůj čas přečtením mé práce za cenné připomínky a zpětnou vazbu.



Prohlašuji, že jsem tuto práci vyřešila samostatně s použitím literatury, kterou uvádím v seznamu.

v Brně dne 28. srpna 2018

.....



**Abstract**

The aim of the work is to introduce the general public to the basic principles of artificial neural networks, including their past, biological prediction its topology. The paper also highlights the current use of neural networks in various fields of human activity included with example and shows some free software for working with neural networks.

**Abstrakt**

Práce si klade za cíl seznámit širokou veřejnost s se základními principy umělých neuronových sítí, a to i s historií tohoto oboru, biologickým předobrazem, a samotnou stavbou sítě. Práce také uvádí aktuální využití, praktickou ukázkou a výběr volně dostupných knihoven pro práci s neuronovými sítěmi.





## Obsah

<b>1</b>	<b>Úvod</b>	<b>11</b>
1.1	Motivace . . . . .	11
1.2	Cíl práce . . . . .	11
<b>2</b>	<b>Historie</b>	<b>12</b>
2.1	Starověk . . . . .	12
2.2	Současné dějiny . . . . .	12
<b>3</b>	<b>Obecná teorie</b>	<b>13</b>
3.1	Biologická předloha . . . . .	13
3.2	Umělý neuron . . . . .	13
3.3	Neuronová síť . . . . .	14
3.4	Učení neuronové sítě . . . . .	14
<b>4</b>	<b>Problémy</b>	<b>15</b>
4.1	(Ne)Omylnost . . . . .	15
4.2	Zneužití . . . . .	16
<b>5</b>	<b>Využití</b>	<b>17</b>
5.1	Komprese dat . . . . .	17
5.2	Filtrace šumu . . . . .	17
5.3	Zpracování obrazu . . . . .	17
<b>6</b>	<b>Práce s neuronovými sítěmi</b>	<b>18</b>
6.1	Získávání dat . . . . .	18
6.2	Návrh sítě . . . . .	18
6.3	Učení sítě . . . . .	18
<b>7</b>	<b>Dostupný software</b>	<b>19</b>
7.1	TensorFlow . . . . .	19
7.2	OpenNN . . . . .	19
7.3	numpy . . . . .	19
<b>8</b>	<b>Praktická ukázka</b>	<b>20</b>
<b>9</b>	<b>Závěr</b>	<b>22</b>
<b>10</b>	<b>Použité zdroje</b>	<b>23</b>



# **1 Úvod**

## **1.1 Motivace**

Aktuální a velmi silnou motivací byl postup do čtvrtého ročníku.

## **1.2 Cíl práce**

Cílem mé práce je přiblížit problematiku umělých neuronových sítí širší veřejnosti, přitom však neopomenout ani její biologický předobraz a celkovou historii oboru. Také jsem se sama chtěla dozvědět více o tomto v současnosti velmi progresivním oboru.

## 2 Historie

### 2.1 Starověk

Otázku čím a jak člověk myslí si lidé pokládali již v antice. Kvalita odpovědi na ní byla samozřejmě podmíněna svou dobou, ale i přesto první dochovaný záznam o bližším zkoumání procesů mozku můžeme nalézt již v 7. st. př. n. l. v Egyptě, jak dokládá nález desky na kterém, bylo několikrát použito slovo mozek (staroegyptsky ys) při popisu komplikované operace fraktury lebky dvou Egyptanů. Spis tedy dokládá, že poznatky o mozku byly už na velmi vysoké úrovni.

Podstata myšlení tedy lidstvo trápila už od pradávna, poznatky o ní prošly postupem času mnoha obměnami a zvyšovala se i jejich úroveň. V počátečních obdobích se uplatňoval tzv. přístup zvnějšku, to znamená, že se o podstatě věci soudilo podle vnějších projevů.

### 2.2 Současné dějiny

Teprve mnohem později rozvoj fyziologie a neurologie umožnil zkoumat ‘zevnitř’, tedy poznat strukturu mozku a funkční podstatu myšlení. v současnosti kombinujeme oba postupy, jak vnější tak vnitřní a právě vnitřní poznávání prošlo v 2. pol. 19. st. a 1. pol. 20. st. značným rozvojem. To hlavně díky postupu vědy o buňkách a živých organismech. Významné jsou v této oblasti zejména práce našeho Jana Evangelisty Purkyně.

Konečně v posledních desetiletích se k nim přidružil ještě další významný přístup - vytváření matematických modelů. Průkopníkem tohoto směru byl američan Warren Sturgiss McCulloch, který v roce 1943 publikoval první reálně použitelný matematický model neuronu. McCullochův model neuronu našel v době po druhé světové válce hojného využití a přesto, že byl pak mnoha dalšími autory mnohokrát modifikován, doplňován a zlepšován, je základem naprosté většiny umělých neuronových sítí až dodnes.

Intenzivní rozvoj umělých neuronových sítí pak nastává s koncem druhé světové války.

## 3 Obecná teorie

### 3.1 Biologická předloha

Nervový systém a především lidský mozek, ač je nejúžasnější procesor, který dosud známe, je ve své podstatě tvořen ze 100 miliard jednoduchých nervových buněk. Každá takhle buňka dokáže přijímat, zpracovávat a přenášet informace prostřednictvím elektrických a chemických signálů.

Typický neuron je rozdělen na tyto tři části: *soma* – tělo, *dendridy* – tenké přijímače, které se rozvětvují z těla buňky a *axon* – vysílač, který má každý neuron jen jeden. Signály jsou do ostatních neuronů vysílány axonem v místě, které se nazývá *synapse* – rozhraní, což je jednosměrná brána připojená na dendrid dalšího neuronu pro předání signálu. Přenos těchto signálů je ovlivněn *excitátory* – budící látkou a *inhibitory* – tlumící látkou synapse. Aktivace neuronu nastává právě tehdy, když je míra excitátoru větší než míra inhibitoru o určitý práh.

V lidském těle je celá řada typů neuronů podle jejich specializace, některé reagují na podněty jako je dotyk, zvuk, světlo pach nebo chuť a jiné přijímají signály z mozku a míchy a způsobí zatnutí svaloviny nebo ovlivnili tvorbu hormonů. Všechny tyto buňky potom skládají náš nervový systém, do kterého patří právě mozek a mícha.

### 3.2 Umělý neuron

První matematický model měl své vstupy  $x_1, x_2, \dots, x_n$ , které byly binární, čili mohly nabývat pouze hodnot 1 nebo 0. Tyto vstupy se vynásobily váhami  $w_i$  (kde  $i$  je index vstupu), které byly pevně na hodnotě -1 pro inhibitory a 1 pro excitátory. Výstupem tohoto neuronu potom byla 1 pro  $\sum_{i=1}^n w_i x_i \geq \text{práh}$  a 0 pro  $\sum_{i=1}^n w_i x_i < \text{práh}$ . Tento model však neuměl všechny logické funkce. O 15 let později byl uveden umělý neuron, ve kterém  $x$  i  $w$  byly tentokrát vektory a na svém výstupu měl aktivační nespojitou funkci  $f$  takovou, že  $f = \sum_{i=1}^n w_i x_i + \text{práh}$ . Pro lepší fungování neuronové sítě a jejího učení se používá sigmoida.

Mezi nejčastěji užívané aktivační funkce patří:

- bipolární binární
- unipolární binární
- bipolární spojitá
- unipolární spojitá
- lineární
- relu

### 3.3 Neuronová síť

Ted', když už víme jak funguje jeden neuron můžeme je poskládat do neuronové sítě. Tím, jakým způsobem neurony pospojujeme, se zabývá *topologie*. Síť je rozdělena do *vrstev*, přičemž jedna vrstva je soubor neuronů, které mají jednosměrné vazby pouze na neurony vrstvy následující. Neurony výstupní vrstvy dále posílají už jen výstup sítě. Když máme  $k \geq 2$  vrstev neuronů hovoříme o  $k$ -vrstvé síti o  $k - 1$  skrytých vrstvách. *Perceptron* je síť skládající se jen z jednoho neuronu.

Neuronové sítě rozdělujeme podle šíření na *feedforward networks* – dopředné a *feedback networks* – zpětné. Feedforward je síť, ve které se signál přemísťuje plynuce ze vstupu na výstup. Ve feedback síti se signál po výpočtu vrátí rekurentně zpět na začátek sítě, počet vstupů se tedy musí rovnat počtu výstupů. Takováto síť se zastaví až tehdy, dosáhne-li *rovnovážného stavu* – výstup sítě se rovná minulému výstupu sítě nebo *rovnovážného cyklu* – stav ve kterém se výstupy periodicky opakují.

### 3.4 Učení neuronové sítě

Aby neuronová síť kvalitně pracovala, musí se napřed co nejpřesněji nastavit míra vah a prahů. U některých typů sítí je možné toto provést čistě algebraicky. U většiny však musíme (a chceme – hlavně o tomto jsou neuronové sítě) použít metodu učení. Rozlišujeme dva typy učících metod: *supervised learning* – učení s učitelem a *unsupervised learning* – učení bez učitele.

Supervised learning spočívá v tom, že síti dáme tréninková vstupní data plus jejich správný výstup. Po "nakrmení" sítě učící algoritmus porovná svůj výstup se výstupem předpokládaným a na základě toho upraví váhy a prahy. Tak může učinit po každém výpočtu, na konci cyklu – po projetí všech tréninkových dat – nebo kombinaci těchto dvou. Učící algoritmus dále iteruje tyto tréninková data. Musíme si ale dát pozor na *overfitting* – přeučení, stav kdy síť po příliš mnoha iteracích nachází zákonitosti, které ale obecně neplatí. Aby nedošlo k overfittingu, měla by se tréninková data ze sady vybírat v náhodném pořadí, nemělo by se iterovat přesprávně a 1/5 tréninkových dat bychom měli dát bokem, jako validační pojistku. Opakem overfittingu je (nečekaně) *underfitting* – nedostatečné natrénování, stav kdy je kvůli nedostatku tréninkových dat síť příliš obecná.

U *unsupervised learningu* síti předkládáme jen vstupy. Sama se poté snaží najít zákonitost aby podobné vstupy měly podobné výstupy.

## 4 Problémy

### 4.1 (Ne)Omylnost

Úplně stejně jako mozek i neuronová síť není ve všem neomylná, a to i za předpokladu, že pracuje jak má. Samozřejmě záleží na povaze úkolu a typu sítě. Stejně jako ve fyzice zde ale převážně pracujeme se statistickými odchylkami v důsledku nepřesnosti vstupních dat. Když budeme dále sledovat podobnost s fyzikou, kde se tato odchylka zmenšuje opakováním pokusu, dojdeme k názoru, že i neuronová síť by měla výpočet ověřit. Ale jelikož již naučená síť bude pracovat se stejnými daty stejným způsobem musíme chybu eliminovat pojištěním sítě sítí další.

Kde tedy neuronovou síť použít? (příklad):

- celkové pilotová civilního letadla – tady NE
- havarijní autopilot pro nadzvukové tryskáče kde hrozí, že pilot kvůli přetlaku omdlí a bude se počítat každá vteřina – tady ANO

Zkrátka je na nás rozhodnout, do čeho je vhodné ji pustit a do čeho ne.

## 4.2 Zneužití

Pokud jste někdy používali Snapchat nebo Instagram, určitě jste si všimli že u focení existují tzv. filtry. Narozdíl od filtrů na pozdější úpravu fotky vám tyto funce umožňují v reálném čase přimalovat na obličej psí čumák i s oušky nebo speciální efekty plivat oheň. Nejzajímavější z těchto filtrů je však *Face Swap* – prohození obličeje. Tato funke (jak už název naznačuje) umí za použití augmented reality prohodit váš obličej s jakýmkoliv použitelným obličejem z vaší galerie. Třeba i s člověkem kterého jste v životě nepotkali. Stačí fotky s rozpoznatelným obličejem. Tato technologie byla v minulosti vyhrazená pro speciální animátory ve filmech a rozhodně nezahrnovala jen vybrání si pěkné fotky protagonisty. Ač je face swap ze Snapchatu daleko méně uvěřitelný než stahodinové práce filmových animátorů, pořád je to jedna z nejzábavnějších funkcí této aplikace.

Toho si všimli i tvůrci aplikace FakeApp – falešná aplikace – kteří na základě Google open sourced machine learning technology vytvořili aplikaci, která po té co jí "nakrmíte" dostatečným množstvím různých póz jednoho obličeje a ona za to vyprodukuje falešné video. Takto přetvořená videa se jmenují deepfake a je překvapivě jednoduché je vytvořit. Zatímco většina takto vzniklých videí jsou parodie a sketche (jako například scéna z filmu Superman kde mezi sebou vedou dialog Superman a tělo Lois Lane s obličejem Nicholase Cage), FakeApp si bohužel našel cestu i do temnějších zákoutí internetu. Ještě teď si vybavuji zapálenou hádku mezi mnou a babičkou, kde si bábi trvala na tom, že v pomerančích z Libye je HIV. Samozřejmě šlo o hoax. Z první vlny šoku se naštěstí lidé rychle oklepali a na internetu už tou dobou bylo spoustu článků vysvětlujících proč je to blbost. Babička mi tedy musela dát za pravdu, ale i tak na dalšího půl roku pomeranče z naší domácnosti záhadně zmizely. Fake news a hoax nadále zůstávají strašáci internetu a bohužel ne každý zdravým rozumem posoudí důvěryhodnost zdroje nebo nedejbože si na danou problematiku něco přečte. Facebooku, který je líhní těchto zpráv, však neumí systematicky tyto klamy regulovat. Což teprve pak videa.



## 5 Využití

### 5.1 Komprese dat

Využívají se při optimalizacích komprimačních algoritmů, které mohou znatelně snížit velikost souboru bez újmu na kvalitě. Stejně tak snížit výpočetní náročnost potřebnou ke komprimování dat.

### 5.2 Filtrace šumu

Při filtraci šumu ze zdrojů podobných charakteristik je možné použít neuronovou síť k rozeznání zdánlivě náhodných vzorů a tím zvýšit efektivitu filtrace.

### 5.3 Zpracování obrazu

Zjistilo se, že člověk je velmi dobrý v rozpoznávání vzorů a objektů v obrazu. Neuronové sítě, které jsou lidskému mozku podobné, se dají velmi dobře využít při hledání vzorů nebo jiné dekompozici obrazu (např. obor počítačového vidění).

## 6 Práce s neuronovými sítěmi

Praktické využití neuronové sítě k vyřešení daného problému většinou není jen o jejím návrhu. Mnoho problémů je lepší řešit jinými způsoby a i když se pro řešení nějakého problému jeví neuronová síť jako vhodná, může i poté nastat několik překážek, přes které se dané řešení nedokáže přenést.

### 6.1 Získávání dat

První známkou toho, že problém není dobře řešitelný neuronovou sítí, je množství dostupných testovacích dat. Pro učení neuronové sítě je obecně potřeba velké množství testovacích úkolů a jejich správných výsledků pro kontrolu. Pokud se například pomocí neuronové sítě snažíme rozpoznat psané číslice, potřebujeme mnoho obrázků číslic i s informací, která číslice je daném obrázku napsána. Čím méně dat máme, tím těžší bude správně neuronovou síť navrhnout a tím nepřesnější výsledná neuronová síť bude. Obecně tedy existují dva přístupy: generování a sbírání dat. Některé problémy umožňují vyrobit náhodný generátor vstupních problémů, na kterých se neuronová síť naučí pracovat a může poté řešit vstupní problémy z reálného světa. Mnohem častěji je však potřeba vstupní data nasbírat například z různých internetových zdrojů nebo od velkého množství uživatelů.

### 6.2 Návrh sítě

Dalším krokem, který vyžaduje největší znalosti a zkušenosti s neuronovými sítěmi je jejich návrh. Při návrhu musíme brát v potaz několik faktorů: jaká je povaha problému, jaká je jeho složitost, kolik vstupních dat máme nebo jak výkonnými počítači disponujeme. Měli bychom znát výhody, nevýhody i jiné vlastnosti jednotlivých vrstev neuronů a aktivačních funkcí. Také bychom měli umět odhadnout vhodnou velikost (počet neuronů) jednotlivých vrstev i celých sítí. Obecně totiž platí, že čím větší neuronovou síť navrhne, tím náročnější bude její učení - jak časově, tak na množství vstupních dat.

### 6.3 Učení sítě

S navrženou neuronovou sítí a dostatkem testovacích dat je učení neuronové sítě již jednoduchým krokem. I zde ovšem můžeme efektivitu sítě vylepšit různými technikami, jako například promícháním vstupních dat nebo dočasným odpojením náhodných neuronů tak, aby váhy v síti byly rozložené rovnoměrně a síť nebyla přehnaně závislá na jednom konkrétním neuronu. Také musíme zvolit správný počet opakování učícího procesu, aby nedošlo k overfittingu ani underfittingu.

## 7 Dostupný software

Pro práci s neuronovými sítěmi dnes existuje velké množství knihoven a jiných nástrojů, takže člověk již nepotřebuje implementovat neuronovou síť z ničeho a neuronové sítě mohou prakticky využít i matematictí a inženýrští začátečníci. Pro většinu rozšířených programovacích jazyků dnes existuje minimálně jedna knihovna pro tvoření a učení samotných neuronových sítí. Kromě toho jsou dostupné i knihovny pro práci s daty a jejich zobrazení, které také významně zjednodušují práci s neuronovými sítěmi.

### 7.1 TensorFlow

TensorFlow je asi nejrozšířenější knihovna k návrhu neuronových sítí obsahující i mnoho dalších nástrojů souvisejících s prací s neuronovými sítěmi. Je open-source a je pod správou Googlu. Má velkou uživatelskou komunitu a dobrou dokumentaci, takže je dobrá pro začátečníky. Původně byla vyvinutá pro Python, ale existují i varianty pro JavaScript, C/C++.

### 7.2 OpenNN

OpenNN je oproti TensorFlow napsaná původně v C++ a je proto i rychlejší. Není tolik využívána a oproti TensorFlow má méně funkcí, ale díky svému grafickému vývojovému prostředí je vstřícnější pro začátečníky.

### 7.3 numpy

numpy je knihovna pro Python pro práci s daty. S neuronovými sítěmi nemá sama o sobě nic společného, ale většinou se používá k úpravě dat a datové typy definované v rámci numpy jsou podporované i v TensorFlow.

## 8 Praktická ukázka

Při práci na mé praktické ukázce jsem si musela napřed odpovědět na několik zásadních otázek:

- Co za programovací jazyk použiji?
- Co za knihovnu použiji?
- Kde seženu testovací data aby jich bylo dost?
- A (v neposlední řadě) co to vůbec má dělat??

Jako knihovnu jsem si vybrala TensorFlow, protože je to velmi rozšířená knihovna s dobrou programátorskou komunitou a obsahuje tutoriály pro úplné začátečníky. Z programovacích jazyků podporuje jak C++ tak i Python, ve kterém jsem se rozhodla ukázkou naprogramovat. Jako úkol jsem si vybrala naprogramovat síť, která z obrázku pozná, o jaký druh oblečení se jedná. Tento úkol jsem si vybrala zejména proto, protože již existuje volně dostupná standardizovaná databáze obrázků s oblečením. Je to relativně lehký úkol, na kterém se mnoho začátečníků učí navrhovat neuronové sítě, takže také mohu porovnat svou neuronovou síť s ostatními.

1. Databázi obrázků i s načítací funkcí jsem získala zde:  
<https://github.com/zalandoresearch/fashion-mnist>
2. Načítací funkce vrátila pole obrázků - tedy trojrozměrné pole čísel od 0 do 255 o rozměrech Nx28x28, kde N je počet obrázků a 28x28 je rozměr jednoho obrázku.
3. Před načtením do sítě jsem data upravila: dvojrozměrné obrázky jsem převedla na jednorozměrné pole (výsledný tvar pole Nx784) a barvy normalizovala z rozsahu 0-255 na 0-1.
4. Navrhla jsem trojvrstvou síť složenou z hustě propojených vrstev. Poslední vrstva má 10 výstupních neuronů, přičemž číslo v každém neuronu představuje pravděpodobnost, že na obrázku je daný druh oblečení.

```
network = keras.Sequential([
    keras.layers.Dense(300, activation=tf.nn.relu,
                        input_shape=(784,)),
    keras.layers.Dense(80, activation=tf.nn.relu),
    keras.layers.Dense(10, activation=tf.nn.softmax)
])
```

5. S pomocí vstupních trénovacích dat jsem neuronovou síť natrénovala. Počet opakování jsem zvolila na 10.

```
network.fit(train_images, train_labels, epochs=10)
```

6. Přesnost neuronové sítě jsem ověřila na testovacích datech, které se od trénovacích liší. Přesnost neuronové sítě byla zhruba 88 %.

Výsledkem je natrénovaná neuronová síť, se kterou mohu teoreticky rozpoznávat druh oblečení na černobílých obrázcích o rozměrech 28x28.

Kompletní kód neuronové sítě je k dispozici zde:

<https://github.com/AndyHaupt/ZMP/blob/master/fashion.py>

Ukázkové řešení na webu TensorFlow:

[https://www.tensorflow.org/tutorials/keras/basic\\_classification](https://www.tensorflow.org/tutorials/keras/basic_classification)

## 9 Závěr

V mé práci jsem postupně popsala fungování jak jednoho umělého neuronu tak celé sítě. Zároveň jsem neopomenula historii tohoto oboru a proč vycházel právě z biologie. Po příkladech kde se umělá neuronová síť využívá jsem uvedla i důvod proč není vhodné ji používat na místech jiných a také kde už člověku aktivně škodí. Dále jsem zformulovala základní principy práce s neuronovou sítí, uvedla příklady volně dostupných knihoven a popsala postup při programování mé vlastní sítě.

## 10 Použité zdroje

1. NOVÁK, Mirko. Umělé neuronové sítě: teorie a aplikace. Praha: C.H. Beck, 1998. Učebnice informatiky. ISBN 80-7179-132-6.
2. FI MUNI - Úvod do umělé inteligence [online]. [cit. 2018-06-12]. Dostupné z: <https://nlp.fi.muni.cz/uui/#slajdy>
3. Introduction to Neural Networks, Advantages and Applications [online]. [cit. 2018-06-12]. Dostupné z: <https://towardsdatascience.com/introduction-to-neural-networks-advantages-and-applications-96851bd1a207>
4. Artificial Neural Networks Applications: From Aircraft Design Optimization to Orbiting Spacecraft On-Board Environment Monitoring [online]. [cit. 2018-06-12]. Dostupné z: <https://ntrs.nasa.gov/archive/nasa/casi.ntrs.nasa.gov/20020081338.pdf>
5. RADOVÁ, Vlasta. Neuronové sítě [online]. [cit. 2018-08-09]. Dostupné z: <https://docplayer.cz/9519980-Neuronove-site-vlasta-radova-zapadoceska-univerzita-v-plzni-katedra-kybernetiky.html>
6. RADOVÁ, Vlasta. Typy umělých neuronových sítí [online]. [cit. 2018-08-09]. Dostupné z: [http://www.kky.zcu.cz/uploads/courses/nses/2\\_Typy\\_umelych\\_neuronovych\\_siti\\_a\\_faze\\_jejich\\_cin](http://www.kky.zcu.cz/uploads/courses/nses/2_Typy_umelych_neuronovych_siti_a_faze_jejich_cin)
7. Neural Networks and Deep Learning [online]. [cit. 2018-08-09]. Dostupné z: <https://www.coursera.org/learn/neural-networks-deep-learning/home>
8. Neuronové sítě [online]. [cit. 2018-08-09]. Dostupné z: [https://is.mendelu.cz/eknihovna/opory/zobraz\\_cast.pl?cast=21471](https://is.mendelu.cz/eknihovna/opory/zobraz_cast.pl?cast=21471)